


웨이퍼 맵 불량 패턴 분류

lot 단위로 나눈 평가에서 macro-F1 0.909를 확인한 소형 CNN


WM-811K 공개 데이터



이진성

01 개요와 진행 방식

복사본 누수를 막은 평가에서 macro-F1 0.909.
7시간 40분 동안 체크포인트 6개에서 판단 13건, 별도 검증 에이전트 35개를 병렬 운용



데이터	WM-811K 웨이퍼 맵 811,457장 중 라벨 있는 172,950장, 불량 패턴 9종
문제	같은 웨이퍼의 복사본이 학습과 평가에 섞이는 누수를 막고, 새 lot에서 성능 재기
결과	macro-F1 0.843(베이스라인) → 0.909(CNN), 모든 패턴 recall 0.77 이상
투입 자원	1인 7시간 40분, GPU 학습 5회 3시간 36분, 스크립트 12개 1,766줄, 커밋 16회

- 진행 방식

역할

구현·실험·문헌 조사 Claude Code / 문제 정의·평가 설계·판단·검증 본인

규칙

판단 지점에서 멈추고 선택지 2~3개와 장단점 제시 · 숫자는 실행 결과에서만 · 오류는 발견자까지 기록

검증

구현과 분리한 에이전트 35개(워크플로 8회)가 재계산·반박 → 오류 15건 중 7건 적발

02 문제 정의: 데이터와 평가 방식

에이전트 10개가 찾은 이상점 17개 중 복사본 누수를 핵심 문제로 선정. lot과 복사본을 한 묶음으로 나누는 규칙 수립

누수 3겹


원본 분할	test 3,158장이 train의 복사본
lot 단위 분할	재검사 복사본이 양쪽에 남음(Center 40.7%)
반전·회전	뒤집거나 돌린 복사본까지 8가지 변환으로 비교

채택한 분할 lot + 10픽셀 이내 복사본을 한 묶음으로 70:15:15


성공 기준 macro-F1 0.80 이상,
모든 패턴 recall 0.50 이상, 베이스라인 초과

Claude Code	탐색·분할 스크립트 구현. 이상점 탐색 에이전트 10개 29분 → 스크립트 재검산 1분 39초
본인	정제 규칙·분할 방식·성공 기준 결정(판단 지점 6·7)

test 웨이퍼 중 학습 쪽에 10픽셀 이내 복사본이 있는 비율



같은 맵, 다른 라벨: 원본 Training/Test 사이 복사본 14쌍 중 4쌍



03 방법과 결과


AI가 제시한 개선 방향 3개 중 소형 CNN + val 보정을 선택. 같은 test 25,444장에서 macro-F1 0.843 → 0.909

모델	macro-F1 (95% CI)	최저 recall
베이스라인 (특징 23개 + RF)	0.843 (0.820–0.858)	0.497 (Loc)
소형 CNN	0.901 (0.863–0.918)	0.763 (Loc)
소형 CNN + val 보정 (최종)	0.909 (0.885–0.922)	0.775 (Loc)

체크포인트 3: AI가 보고한 후보	내 결정 (판단 지점 8)
① 소형 CNN: 맵을 격자로 맞추고 회전·반전 증강 ② 특징 강화 + 부스팅: 개선 폭 제한 ③ 사후 임계값 보정: 드문 패턴은 val 과적합 위험	①+③ 조합, 입력은 64×64 불량 보존 축소. weighted CE는 같은 test에서 비교 → 0.825로 폐기. 보정값은 val에서만 → 0.909

Claude Code 특징 23개·RF·CNN 구현, 학습 5회(GPU 3시간 36분)

본인 개선 방향·입력 크기 결정(판단 지점 8), weighted CE 폐기(판단 지점 10)




예상보다 높은 점수 → 학습이 도는 동안 검증 에이전트 4개 병렬 + 개입 실험 → 분할 절차 오류 1건 발견·수정

검증	방법	결과
우연 수준	라벨을 섞어 학습	macro-F1 0.102
누수 제거 효과	무작위 분할 vs lot 분할	0.895 vs 0.909
지름길 학습	제품 외곽선을 바꿔 끼움	예측 99.5% 유지
오분류 검토	96장, 라벨 가린 독립 판정	라벨 의심 27%
재현	새 폴더에서 처음부터 재실행(자동, 1시간 8분)	10개 항목 일치

AI가 낸 오류 15건 중 검증 에이전트가 잡은 7건의 예

- E10** AI가 세운 원인 가설을 AI가 짠 진단 스크립트가 반증 → 가설 철회
- E11** 반박 검증 에이전트가 scikit-learn 소스와 개입 실험으로 분할 오류 확인 → 전부 재학습
- E13** 지표 검증 에이전트가 보정 결과를 재현하다 확률 열 버그 발견 → 저장 로직 수정



분할 절차 오류 (LOG E11)

- 원인** StratifiedGroupKFold가 큰 그룹을 seed와 무관하게 같은 fold에 고정 → 쉬운 Loc 132장이 항상 test
- 발견** 베이스라인이 이유 없이 오름 → seed 10개로 재분할 → lot 묶음 하나를 빼 보는 실험
- 수정** fold 배정 무작위 치환, 전 모델 재학습(0.893 → 0.909), 분할 후 겹침 검사 추가

같은 제품의 새 lot에 대한 1차 분류 보조 수준. 수율 개선 효과는 주장하지 않음

결론

- 누수를 막은 평가에서 CNN 0.909, 베이스라인 0.843
- 분할 절차 하나로 Loc recall 12%p 차이. 모델보다 평가 방식부터 확인
- 구현과 분리한 검증 에이전트가 오류 15건 중 7건 적발.
새 폴더 재현 일치

한계·다음 단계

- 한 번 나눈 분할. seed 10개 평균은 약 0.01 낮음 → 그룹 5-fold
- Near-full test 18장, 신뢰구간 0.70–1.00
- 짧은 Scratch 약점, 라벨 노이즈 14쌍 → 라벨 기준 재정의

재현 정보

환경 Python 3.12.6, torch 2.7.1+cu118, scikit-learn 1.9.1, Quadro P2000, 시드 0
실행 python scripts/run_all.py (약 4~5시간) → outputs/*.json
근거 파일 첨부 zip과 github.com/sl2ver/wm811k-wafer-defect-classification(공개)에 같은 구조로: PLAN.md / LOG.md(지시 원문·판단·오류 기록) / RESULT.md / scripts / outputs