

웨이퍼 맵 결함 패턴 분류: 누수 없는 평가에서 macro-F1 0.843 → 0.909

2026.09.27 24시간 개인 해커톤(7시간 40분 사용) · 판단 13건과 전 과정 검증: 본인 / 코드 구현·실험·조사: Claude Code · 새 환경 재현 일치

이진성

서울과학기술대학교 전기정보공학과 석사과정 · RF/EMC 계측
계측 데이터를 다루던 습관(수치는 측정에서만, 결과는 재현으로 확인)을 처음
만지는 반도체 제조 데이터에 그대로 적용해 본 24시간 연습

0.909


macro-F1 (9클래스, test
25,444장)
95% CI 0.885–0.922 ·
베이스라인 0.843

0.775

가장 낮은 클래스 recall
(Loc)
베이스라인 0.497 → 모든
클래스 0.50 이상

10 / 10

새 폴더 재현에서 일치한
항목
clone → 데이터 → 학습 →
평가, 1시간 8분



WM-811K 결함 패턴 9종 예시 · 회색 = 정상 다이, 파란색 = 불량 다이 · 라벨 있는 웨이퍼 172,950장 중 무작위 표본

이 문서는 분류 성능을 검증한 결과이며, 수율 개선이나 공정 원인 규명 효과는 주장하지 않는다.

원본 Test의 3,158장은 Training의 복사본이었다 — lot과 쌍둥이 맵을 한 덩어리로 묶어 다시 나눴다

WM-811K 811,457장 · 라벨 172,950장(none 85%, Near-full 149장 = 989 : 1) · 정제 후 169,680장을 70 / 15 / 15로

누수 1 · 복사본 원본 Training과 Test 사이에 픽셀까지 같은 맵 3,158장(Test의 2.7%). 그중 14쌍은 라벨도 서로 다름


누수 2 · 재기록 사본 lot 단위로 나뉘어도 이웃 lot에 1~10픽셀만 다른 맵이 남음. test Center의 41%에 학습 쪽 사본

누수 3 · 변환·재검사 사본 상하 반전·회전한 사본, 불량 다이만 늘어난 재검사본(11~66픽셀 차이)


결정 라벨 충돌 14쌍·중복 3,238장·조각 맵 4장 제외. 반전·회전 8종 중 어느 것으로든 차이가 max(10, 불량 다이 10%) 이하면 쌍둥이로 보고, 쌍둥이로 이어진 lot을 한 덩어리로 묶어 분할 → train-test 겹침 0

성공 기준 (사전 확정) macro-F1 0.80 이상 · 모든 클래스 recall 0.50 이상 · 베이스라인 초과. 신뢰구간은 덩어리 단위 부트스트랩 1,000회

같은 맵, 다른 라벨 — 원본 Training/Test 사이의 복사본 14쌍 중 4쌍



test 웨이퍼 중 학습 쪽에 10픽셀 이내 복사본이 있는 비율 (80/20, seed 0)



특징 23개 + 랜덤 포레스트 0.843 → 맵을 직접 보는 소형 CNN 0.909, Loc·Scratch에서 가장 크게 올랐다

같은 정제 데이터 · 같은 분할 · 같은 test 25,444장 · 모델 선택은 val만으로 · 대괄호는 95% 신뢰구간

모델	macro-F1 (9종)	결합 8종	최저 recall
베이스라인: 특징 23개 + RF	0.843 [0.820–0.858]	0.826	0.497 (Loc)
CNN · CE	0.901 [0.863–0.918]	0.889	0.763 (Loc)
CNN · CE + 보정 (최종)	0.909 [0.885–0.922]	0.899	0.775 (Loc)


입력 64×64 비등방 리사이즈, 축소 시 블록 최대값으로 1다이 폭
Scratch 보존 · 반전·회전 8종 증강

모델 합성곱 블록 4개, 파라미터 58만, CE 20 epoch(GPU 40분) ·
클래스별 bias는 val에서만 맞춤

효과 없던 시도 class-weighted CE: 0.825 (none 오탐 증가). 분할을
바꿔 두 번 확인해도 같은 결론

짜비고 같은 test에서 CNN만 맞힘 513장 vs RF만 맞힘 177장 (정확
McNemar $p \approx 9e-39$)

용도 · 한계 검토 순서를 정하는 1차 분류 보조. 자동 폐기 판정에는
부적합. 평가 범위는 같은 제품의 새 lot(새 제품은 121장으로만 확인)



좋은 결과를 의심했다 — 분할 절차가 Loc recall을 12%p 부풀린 것을 찾아 고쳤다

순서: 영향 → 원인 → 왜 놓쳤나 → 발견과 수정 → 재발 방지 · 아래 검증 5가지는 모두 스크립트 실행 결과


영향 수정 전 test Loc recall CNN 0.82 · RF 0.62 → 수정 후 0.77 · 0.50. test Near-full의 81%도 덩어리 하나에서 나오고 있었음

원인 scikit-learn 1.9.1의 StratifiedGroupKFold는 크고 치우친 그룹을 seed와 무관하게 같은 fold에 넣는다. 쉬운 Loc 가족 132장(28개 lot, 한 제품)이 항상 test에 들어감

왜 놓쳤나 첫 검증은 '분할 사이 겹침 0'만 확인했고, test 구성이 seed에 따라 바뀌는지는 보지 않음

발견 → 수정 분할 변경 후 베이스라인이 '좋아진' 것을 의심 → seed 10개 재분할에서 규칙 간 Loc 격차 15%p → 가족 하나만 옮기는 개입 실험으로 확인 → fold → 분할 대응을 seed로 무작위 치환하고 전 모델 재학습 (결론 유지, 대표 수치 0.893 → 0.909)

재발 방지 분할 직후 train-test 쌍둥이·lot 겹침 0과 클래스별 최대 덩어리 비중을 검사



서플 라벨 (negative control)

macro-F1 0.102 = 다수 클래스 수준

무작위 분할 vs 주 분할

CNN 0.895 vs 0.909. 누수를 막은 뒤에는 차이 없음

외곽선 개입 실험

25×27 제품 외곽선을 바꿔 끼워도 예측 99.5% 이상 유지 → 지름길 아님

오분류 96장 이중맹검 판정


두 평가자 일치 70%. 애매 46% / 모델 27% / 라벨 의심 27%. 약점은 6~10다이 짧은 Scratch

새 폴더 재현

clone → README 순서 실행 1시간 8분 → 비교 10개 항목 전부 일치

24시간 중 7시간 40분: 체크포인트 6개에서 멈춰 판단 13건을 내리고, 오류 14건을 기록했다

기록: PLAN.md(변경 이력 4건) · LOG.md(지시 원문·판단·오류) · RESULT.md(수치·버린 것 9·한계 9) · GLOSSARY.md · 저장소 공개



시간은 T0(2026-09-27 14:48, 첫 지시) 기준 경과 · 파란 점 = 체크포인트(보고 후 지시 대기), 주황 점 = 오류 발견

내가 정한 것 (13건 중 3건)

라벨 없는 638,507장 제외 분포가 다르고(불량 0개 맵 5.8만 장), 평가 맵의 쌍둥이 5,408장이 섞여 있어서
성공 기준 macro-F1 0.80 선행연구의 lot 분할 0.85는 재기록 사본 누수를 포함했을 가능성, 라벨 노이즈도 확인돼서
불균형은 가중 손실 대신 val 사후 보정 같은 test에서 비교해 채택 (weighted CE 0.825 < CE 0.901)

한계 · 다음 단계

단일 분할 seed 10개 평균보다 약 0.01 낙관 → 그룹 5-fold로 전체 평가
드문 클래스 Near-full test 18장, CI 0.70~1.00 → 표본 확보 전까지 수치 유보
라벨 노이즈 · 짧은 Scratch 같은 맵 다른 라벨 14쌍 → none↔Edge-Loc 기준 재정의, 6~10다이 선용 고해상도 입력

AI와 일한 방식

역할 문제 정의·평가 설계·판단·최종 검토: 본인 / 구현·실험·문헌 조사: Claude Code
경계 누수 판정 기준, 수치 채택, 버그 판정은 위임하지 않음. 체크포인트마다 선택지와 근거를 받아 결정
검증 조사·계산은 독립 에이전트가 반박 검증(오류 14건 중 7건 발견). 배운 것: 수치는 실행에서만, 좋은 결과일수록 먼저 의심