


웨이퍼 맵 불량 패턴 분류

lot 단위로 나눈 평가에서 macro-F1 0.909를 확인한 소형 CNN

WM-811K 공개 데이터 | 개인 프로젝트 | 2026. 9.



이진성

01 프로젝트 개요

구현·실험은 Claude Code, 평가 설계와 판단·검증은 제가 맡았습니다. 새 lot에서 macro-F1 0.909.

데이터	WM-811K 웨이퍼 맵 811,457장 중 라벨 있는 172,950장, 불량 패턴 9종
문제	같은 웨이퍼의 복사본이 학습과 평가에 섞이는 누수를 막고, 새 lot에서 성능 재기
결과	macro-F1 0.843(베이스라인) → 0.909(CNN), 모든 패턴 recall 0.77 이상
AI 활용	Claude Code가 구현·실험, 별도 검증 에이전트 45개가 재검산. 체크포인트 6개에서 판단 13건, 오류 15건 기록

용어 lot: 함께 처리한 웨이퍼 묶음(최대 25장) · macro-F1: 패턴 9종 F1의 평균 · recall: 실제 그 패턴 중 맞힌 비율

진행 순서

1 문제 정의와 평가 설계	3쪽
2 베이스라인과 소형 CNN	4쪽
3 검증과 오류 수정	5쪽
4 AI 활용 ① 지시와 역할	6쪽
5 AI 활용 ② 검증과 오류 적발	7쪽
6 결론·한계·재현 정보	8쪽

02 문제 정의: 데이터와 평가 방식

AI 에이전트 10개가 찾은 이상점 17개 중 복사본 누수를 핵심 문제로 정하고, lot과 복사본을 한 묶음으로 나눴습니다.

누수 3겹


원본 분할	test 3,158장이 train의 복사본
lot 단위 분할	재검사 복사본이 양쪽에 남음(Center 40.7%)
반전·회전	뒤집거나 돌린 복사본까지 8가지 변환으로 비교

채택한 분할 lot + 10픽셀 이내 복사본을 한 묶음으로 70:15:15


성공 기준 macro-F1 0.80 이상,
모든 패턴 recall 0.50 이상, 베이스라인 초과

Claude Code	탐색·분할 스크립트 구현, 이상점 탐색 에이전트 10개 병렬 실행
본인	정제 규칙·분할 방식·성공 기준 결정(판단 지점 6·7)

test 웨이퍼 중 학습 쪽에 10픽셀 이내 복사본이 있는 비율



같은 맵, 다른 라벨: 원본 Training/Test 사이 복사본 14쌍 중 4쌍



03 방법과 결과


구현은 AI에 맡기고 개선 방향과 채택 기준은 제가 정했습니다.
같은 test 25,444장에서 macro-F1 0.843 → 0.909.

모델	macro-F1 (95% CI)	최저 recall
베이스라인 (특징 23개 + RF)	0.843 (0.820–0.858)	0.497 (Loc)
소형 CNN	0.901 (0.863–0.918)	0.763 (Loc)
소형 CNN + val 보정 (최종)	0.909 (0.885–0.922)	0.775 (Loc)

방법 64×64 축소(블록 최대값으로 Scratch 보존),
반전·회전 증강, 합성곱 4블록 58만 파라미터.
보정값은 val에서만 정함

효과 없던 시도 class-weighted CE: 0.825,
none 오탐 증가 → 미채택


Claude Code 특징 23개·RF·CNN 구현, 학습 5회
본인 개선 방향과 입력 크기 결정(판단 지점 8),
weighted CE 폐기(판단 지점 10)



점수가 예상보다 높게 나오자 검증 에이전트 4개와 개입 실험을 돌렸고, 분할 절차의 오류 하나를 잡아 고쳤습니다.

검증	방법	결과
우연 수준	라벨을 섞어 학습	macro-F1 0.102
누수 제거 효과	무작위 분할 vs lot 분할	0.895 vs 0.909
지름길 학습	제품 외곽선을 바꿔 끼움	예측 99.5% 유지
오분류 검토	96장, 라벨 가린 독립 판정	라벨 의심 27%
재현	새 폴더에서 처음부터 재실행	10개 항목 일치

Claude Code 검증 에이전트 4개 병렬, 개입 실험 구현
본인 오류 판정, 전부 재학습 결정(판단 지점 9)



분할 절차 오류 (LOG E11)

- 원인** StratifiedGroupKFold가 큰 그룹을 seed와 무관하게 같은 fold에 고정 → 쉬운 Loc 132장이 항상 test
- 발견** 베이스라인이 이유 없이 오름 → seed 10개로 재분할 → lot 묶음 하나를 빼 보는 실험
- 수정** fold 배정 무작위 치환, 전 모델 재학습(0.893 → 0.909), 분할 후 겹침 검사 추가

05 AI 활용 ① 지시와 역할

첫 지시문에 AI가 할 일과 멈출 지점, 기록 규칙을 정해 두고 체크포인트 6개에서 판단 13건을 내렸습니다.

첫 지시문의 규칙 (원문)

“판단이 필요한 지점에서는 멈추고 나에게 묻는다.
선택지 2~3개와 각각의 장단점을 제시하고, 추천이 있으면 이유와 함께 밝힌다.”
“숫자는 실행 결과에서만 가져온다. 추정치를 결과처럼 쓰지 않는다.”
“오류 기록: 네 코드나 판단이 틀렸던 경우,
누가(나/너) 어떻게 발견했고 무엇을 바꿨는지.”

작업 흐름



근거: docs/wafer_project_prompt.md(첫 지시문), LOG.md 17:04 보고와 판단 지점 8

체크포인트 3: AI의 제안과 내 결정

AI가 보고한 개선 방향 후보	내 결정 (판단 지점 8)
① 소형 CNN: 맵을 격자로 맞추고 회전·반전 증강. 손으로 만든 특징은 모양·위치 정보를 뭉갬. ② 특징 강화 + 부스팅: 가볍지만 개선 폭 제한. ③ 사후 임계값 보정: 빠르지만 드문 패턴은 val 과적합 위험	①+③ 조합. weighted CE는 같은 test에서 비교해 결정하고 보정값은 val에서만. 비교 기준은 test 최고 베이스라인. 결과: weighted CE 0.825로 폐기, 보정 채택 0.909

체크포인트 6개 · 판단 13건 · 워크플로 10회(에이전트 45개) · 오류 15건 · 작업 시간 7시간 40분

06

AI 활용 ② 검증과 오류 적발

구현 AI와 별개의 검증 에이전트 45개가 AI의 오류 15건 중 7건을 잡았고, 8건은 자체 점검 규칙에서 나왔습니다.

AI가 낸 오류를 잡은 사례

오류	어떻게 드러났나	조치
E10 잘못된 원인 가설	AI가 짠 진단 스크립트가 자기 가설을 반증	가설 철회
E11 분할 절차 오류	반박 검증 에이전트가 sklearn 소스와 개입 실험으로 확인	절차 수정, 전부 재학습
E13 확률 열 버그	지표 검증 에이전트가 보정 결과를 재현하다 발견	저장 로직 수정

- 산출물 반려

2회(대시보드 문구, 포트폴리오 1차).
참고 사례를 조사하게 한 뒤 다시 씀
- 규칙

검증 에이전트에는 원본 코드 대신 데이터와
결과 파일만 주고 다시 계산하게 함

검증·조사 워크플로 10회 (에이전트 45개)

단계	에이전트	결과
데이터 확보·문헌 조사	10	조사 5 + 반박 5 → E1~E4
데이터 이상점 탐색	10	탐색 4 + 검증 → 정정 7건
베이스라인·분할 재계산	4	재계산, 재구현, 코드 감사
Loc recall 원인 조사	3	원인 추적·반박 → E11
CNN 검증 2회	8	지표·짜비교·지름길·이중맹검 → E13
문체·포트폴리오 조사	10	대시보드 4, 포트폴리오 6

07 결론·한계·재현 정보

같은 제품의 새 lot에 대한 1차 분류 보조 수준입니다. 수율 개선 효과는 주장하지 않습니다.

결론

- 누수를 막은 평가에서 CNN 0.909, 베이스라인 0.843
- 분할 절차 하나로 Loc recall 12%p 차이. 모델보다 평가 방식부터 확인
- 검증 5종 통과, 새 폴더 재현 일치

한계·다음 단계

- 한 번 나눈 분할. seed 10개 평균은 약 0.01 낮음 → 그룹 5-fold
- Near-full test 18장, 신뢰구간 0.70~1.00
- 짧은 Scratch 약점, 라벨 노이즈 14쌍 → 라벨 기준 재정의

배운 점

- 수치는 실행 결과에서만 옮긴다
- 점수가 갑자기 오르면 원인부터 찾는다
- 새 데이터는 분할과 라벨부터 검사한다

재현 정보

환경	Python 3.12.6, torch 2.7.1+cu118, scikit-learn 1.9.1, Quadro P2000, 시드 0
실행	python scripts/run_all.py (약 4~5시간) → outputs/*.json
저장소	github.com/sl2ver/wm811k-wafer-defect-classification — PLAN.md / LOG.md(판단 13건·오류 15건) / RESULT.md